



**Facultad de Informática y Ciencias Aplicadas Escuela
de Informática**

Cátedra:

Técnicas de producción industrial software II

Sección:

01

Docente:

Jorge Edwin Machado Leiva

Actividad:

Caso práctico aplicado, análisis de datos para aprobar decisiones en la
gestión de talento perfiles ocupacionales y mejora de procesos

Estudiante:

Kevin Humberto Umanzor de la Paz

Carnet : 25-2219-2022

San Salvador, 12 de mayo de 2026

Contenido

Introducción	3
Objetivo general	4
Objetivos específicos	4
Descripción del dataset	5
Preparación de datos en Python	6
Capturas de evidencia:.....	7
Análisis de correlación e interpretación	9
Capturas del desarrollo:	10
Comparación entre modelo de 4 y 5 clústeres	13
Captura de evidencia:	15
Justificación del modelo seleccionado	16
Hallazgos principales	17
Conclusiones y recomendaciones.....	19

Introducción

En el presente caso práctico se desarrolla un análisis de datos aplicado al estudio de ocupaciones, utilizando el dataset `Prestige_modificado.csv`. Este conjunto de datos contiene información relacionada con el nivel educativo, ingresos, porcentaje de mujeres, prestigio ocupacional, código censal y tipo de ocupación. A partir de estos datos, se busca identificar patrones que permitan comprender qué variables influyen o se relacionan con la valoración social de distintas ocupaciones.

El análisis se realizó mediante Python en Google Colab, aplicando un proceso ordenado de carga, revisión, preparación, análisis de correlación, visualización de resultados y agrupación mediante K-Means. Este procedimiento permite trabajar de manera reproducible, ya que cada paso queda documentado mediante código, salidas y gráficos.

Aunque el dataset no pertenece directamente al sector del software, el caso se relaciona con la producción industrial de software porque permite aplicar una lógica de análisis basada en datos para apoyar decisiones organizacionales. En una empresa de desarrollo de software, este tipo de análisis puede utilizarse para valorar perfiles técnicos, gerenciales o de soporte, identificar necesidades de formación, segmentar roles y mejorar la toma de decisiones sobre talento humano.

En este sentido, el caso práctico no se limita únicamente a ejecutar código, sino que busca interpretar los resultados obtenidos y conectarlos con decisiones reales dentro de una organización tecnológica. De esta manera, el análisis permite transformar datos ocupacionales en información útil para comprender perfiles, niveles de especialización y posibles estrategias de mejora en procesos de gestión de talento.

Objetivo general

Aplicar técnicas de análisis de datos y clusterización utilizando Python sobre el dataset `Prestige_modificado.csv`, con el propósito de identificar relaciones entre variables ocupacionales y detectar grupos de ocupaciones con características similares que puedan ser interpretadas dentro de un contexto de producción industrial de software.

Objetivos específicos

- Cargar y preparar el dataset en Python para validar su estructura, tipos de datos y calidad inicial.
- Analizar la relación entre las variables del dataset mediante una matriz de correlación, identificando cuáles tienen mayor asociación con el prestigio ocupacional.
- Aplicar el algoritmo K-Means utilizando modelos de 4 y 5 clústeres para identificar agrupaciones de ocupaciones con características similares.
- Comparar los resultados obtenidos entre ambos modelos de clusterización para determinar cuál ofrece una interpretación más útil del caso práctico.
- Relacionar los hallazgos obtenidos con posibles decisiones aplicadas a la producción industrial de software, perfiles técnicos y mejora de procesos organizacionales.

Descripción del dataset

El desarrollo del presente caso práctico se realizó utilizando el archivo `Prestige_modificado.csv`, un conjunto de datos orientado al análisis ocupacional y social. Este dataset contiene información relacionada con diferentes profesiones y variables asociadas al prestigio ocupacional, permitiendo aplicar técnicas de minería de datos para identificar relaciones, patrones y agrupaciones entre distintas características laborales. El análisis de este tipo de información resulta relevante dentro de contextos organizacionales y tecnológicos, ya que facilita comprender cómo ciertos factores pueden influir en la valoración de distintos perfiles profesionales.

El conjunto de datos está conformado por 103 registros y 7 variables, donde cada fila representa una ocupación específica. Entre las variables incluidas se encuentran el nivel educativo promedio asociado a la ocupación (`education`), el ingreso promedio (`income`), el porcentaje de participación femenina (`women`), el nivel de prestigio ocupacional (`prestige`), el código censal de la ocupación (`census`) y el tipo de ocupación codificado numéricamente (`type_num`). Además, el dataset incorpora una columna categórica llamada `occupation`, la cual identifica el nombre de cada profesión analizada.

Desde una perspectiva analítica, este dataset resulta apropiado para aplicar técnicas de correlación y clusterización, debido a que presenta suficiente variabilidad entre ocupaciones en aspectos como educación, ingresos y prestigio. Estas diferencias permiten identificar patrones relevantes y construir agrupaciones de perfiles ocupacionales con características similares. En el contexto de producción industrial de software, este tipo de análisis puede relacionarse con la clasificación de perfiles técnicos, gerenciales o de soporte.

Preparación de datos en Python

En el presente caso práctico, esta etapa se desarrolló utilizando Python en Google Colab, principalmente con la librería Pandas, la cual facilitó la carga, exploración y validación inicial del dataset.

El primer paso consistió en importar las librerías necesarias y cargar el archivo CSV dentro de un DataFrame. Posteriormente, se realizó una inspección general del conjunto de datos para verificar la cantidad de registros y columnas disponibles. Como resultado, se confirmó que el dataset contiene 103 registros y 7 variables, estructura que coincide con la información esperada para el desarrollo del análisis.

Después de validar las dimensiones del dataset, se revisaron los nombres de las columnas y los tipos de datos asociados a cada variable. Esta verificación permitió confirmar que las variables numéricas fueron interpretadas correctamente como datos enteros o decimales, mientras que la variable occupation fue reconocida como texto. Esta clasificación fue importante porque las técnicas de correlación y clusterización utilizadas posteriormente requieren trabajar principalmente con variables numéricas.

Además, se ejecutaron procesos de validación de calidad para detectar posibles problemas dentro del dataset. Entre ellos, se revisó la existencia de valores nulos y registros duplicados. Los resultados obtenidos mostraron que el conjunto de datos no contiene valores faltantes ni filas repetidas, lo que indica que la información se encontraba en condiciones adecuadas para continuar con el análisis sin necesidad de aplicar procesos adicionales de limpieza o imputación de datos.

Como parte de la preparación, también se generó una estadística descriptiva de las variables numéricas, permitiendo conocer valores promedio, mínimos, máximos y niveles de dispersión. Este análisis preliminar ayudó a comprender mejor el comportamiento general de variables como education, income, women y prestige, identificando diferencias importantes entre ocupaciones y confirmando que existía suficiente variabilidad para aplicar técnicas de análisis exploratorio y agrupación.

Finalmente, durante la etapa de clusterización fue necesario seleccionar únicamente las variables numéricas relevantes y aplicar un proceso de escalamiento utilizando StandardScaler. Este procedimiento permitió normalizar los datos para evitar que variables con magnitudes más altas, como income, dominaran el comportamiento del algoritmo K-Means. Gracias a esta preparación, el dataset quedó listo para desarrollar tanto el análisis de correlación como la identificación de grupos ocupacionales mediante técnicas de minería de datos.

Capturas de evidencia:

1. Preparación de datos en Python, Código de carga del CSV + df.head()

```
In [1]: import pandas as pd
```

Actividad 1. Preparación e inspección inicial del dataset

• Cargar el archivo Prestige_modificado.csv en Python. • Mostrar las primeras filas del dataset. • Validar cantidad de registros y columnas.

```
In [2]: import matplotlib.pyplot as plt
import seaborn as sns
```

```
In [9]: df = pd.read_csv("https://raw.githubusercontent.com/kevinnumanzor17/Caso_Practico-Tecnicas_Produccion/refs/heads/main/Archivos/Prestige_modificado.csv", sep=';')
df.head()
```

```
Out[9]:
```

	occupation	education	income	women	prestige	census	type_num
0	gov.administrators	13.11	12351	11.16	68.8	1113	1
1	general.managers	12.26	25879	4.02	69.1	1130	1
2	accountants	12.77	9271	15.70	63.4	1171	1
3	purchasing.officers	11.42	8865	9.11	56.8	1175	1
4	chemists	14.62	8403	11.68	73.5	2111	1

2. Evidencia estructura y tipos de datos df.shape // df.info()

```
In [10]: print(df.shape)
print(df.head())
print(df.info())
print(df.isnull().sum())

(102, 7)
  occupation  education  income  women  prestige  census  type_num
0  gov.administrators    13.11  12351  11.16    68.8   1113         1
1  general.managers     12.26  25879   4.02    69.1   1130         1
2  accountants         12.77   9271  15.70    63.4   1171         1
3  purchasing.officers  11.42   8865   9.11    56.8   1175         1
4  chemists            14.62   8403  11.68    73.5   2111         1
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 102 entries, 0 to 101
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   occupation  102 non-null     object
1   education   102 non-null     float64
2   income      102 non-null     int64
3   women       102 non-null     float64
4   prestige    102 non-null     float64
5   census      102 non-null     int64
6   type_num    102 non-null     int64
dtypes: float64(3), int64(3), object(1)
memory usage: 5.7+ KB
None
occupation      0
education        0
income           0
women            0
prestige         0
census           0
type_num         0
dtype: int64
```

3. Evidencia calidad de datos. df.isnull().sum() // df.duplicated().sum()

```
In [11]: print(df.duplicated().sum())
print(df.describe())

0
count      education      income      women      prestige      census  \
mean    10.738039    6797.901961    28.979020    46.833333    5401.774510
std      2.728444    4245.922227    31.724931    17.204486    2644.993215
min      6.380000     611.000000     0.000000    14.800000    1113.000000
25%      8.445000    4106.000000     3.592500    35.225000    3120.500000
50%     10.540000    5930.500000    13.600000    43.600000    5135.000000
75%     12.647500    8187.250000    52.202500    59.275000    8312.500000
max     15.970000   25879.000000    97.510000    87.200000   9517.000000

type_num
count    102.000000
mean      1.843137
std       0.817447
min       0.000000
25%       1.000000
50%       2.000000
75%       2.000000
max       3.000000
```


Análisis de correlación e interpretación

Para el desarrollo de esta etapa se utilizó Python junto con la librería Pandas, calculando una matriz de correlación basada en el coeficiente de Pearson. Este coeficiente permite medir la intensidad y dirección de la relación lineal entre dos variables, tomando valores entre -1 y 1. Los valores cercanos a 1 representan relaciones positivas fuertes, los cercanos a -1 indican relaciones negativas fuertes y los valores próximos a 0 reflejan relaciones débiles o inexistentes.

En el presente análisis, la variable principal de interés fue prestige, debido a que representa el nivel de prestigio ocupacional asociado a cada profesión. A partir de la matriz de correlación obtenida, se identificó que las variables con mayor relación positiva respecto al prestigio fueron education e income. La variable education presentó una correlación positiva fuerte de aproximadamente 0.850, indicando que las ocupaciones con mayores niveles educativos tienden a poseer una valoración social más alta. De manera similar, income mostró una correlación positiva considerable de aproximadamente 0.715, lo que sugiere que las ocupaciones con mayores ingresos también suelen estar asociadas a un mayor prestigio ocupacional.

Por otra parte, algunas variables mostraron relaciones negativas o débiles. La variable women presentó una correlación negativa baja con prestige, mientras que census y type_num reflejaron correlaciones negativas más marcadas. Sin embargo, estas últimas deben interpretarse con precaución debido a que funcionan principalmente como códigos o categorías numéricas y no como variables continuas de comportamiento real.

Los resultados obtenidos permiten observar patrones coherentes desde una perspectiva social y laboral. Generalmente, las ocupaciones que requieren mayor formación académica y ofrecen mejores ingresos tienden a ser percibidas como más prestigiosas dentro de la sociedad. Este comportamiento también puede relacionarse con entornos organizacionales y tecnológicos, donde los perfiles más especializados suelen recibir mayor reconocimiento y valoración profesional.

No obstante, es importante aclarar que la correlación no implica causalidad. Aunque exista una relación estadística fuerte entre variables como education y prestige, esto no significa que una variable cause directamente a la otra. El análisis de correlación debe interpretarse como una herramienta exploratoria que ayuda a identificar patrones y relaciones potenciales, las cuales posteriormente pueden complementarse con análisis más profundos o información adicional del contexto organizacional.

Capturas del desarrollo:

1. Matriz de correlación de variables utilizando el coeficiente de Pearson.

```
In [13]: variables_numericas = df.select_dtypes(include=['int64', 'float64'])
matriz_correlacion = variables_numericas.corr()

print(matriz_correlacion.round(3))
print(matriz_correlacion['prestige'].sort_values(ascending=False).round(3))
```

	education	income	women	prestige	census	type_num
education	1.000	0.578	0.062	0.850	-0.823	-0.382
income	0.578	1.000	-0.441	0.715	-0.361	-0.368
women	0.062	-0.441	1.000	-0.118	-0.227	0.251
prestige	0.850	0.715	-0.118	1.000	-0.635	-0.465
census	-0.823	-0.361	-0.227	-0.635	1.000	0.288
type_num	-0.382	-0.368	0.251	-0.465	0.288	1.000

prestige

education	0.850
income	0.715
women	-0.118
type_num	-0.465
census	-0.635

Name: prestige, dtype: float64


2. Relación positiva entre el nivel educativo y el prestigio ocupacional.

Actividad 3. Visualización de resultados


```
In [15]: import matplotlib.pyplot as plt

plt.figure()
plt.scatter(df['education'], df['prestige'])
plt.xlabel('Education')
plt.ylabel('Prestige')
plt.title('Relación entre educación y prestigio')
plt.show()

plt.figure()
plt.scatter(df['income'], df['prestige'])
plt.xlabel('Income')
plt.ylabel('Prestige')
plt.title('Relación entre ingreso y prestigio')
plt.show()
```



3. Relación positiva entre el ingreso promedio y el prestigio ocupacional.



Análisis de agrupación con K-means

El análisis de agrupación o clusterización tiene como objetivo identificar conjuntos de datos con características similares. En el presente caso práctico se utilizó el algoritmo K-Means, una técnica de aprendizaje no supervisado utilizada en minería de datos para segmentar elementos en diferentes grupos según sus características numéricas.

Para desarrollar este proceso, se seleccionaron las variables education, income, women, prestige y type_num, debido a que representan atributos relevantes para describir las ocupaciones incluidas en el dataset. Antes de aplicar el algoritmo, fue necesario realizar un proceso de escalamiento mediante StandardScaler, con el propósito de normalizar las variables y evitar que aquellas con magnitudes más elevadas, como income, dominaran el comportamiento del modelo.

Posteriormente, se construyeron dos modelos de agrupación distintos utilizando K-Means: uno con 4 clústeres y otro con 5 clústeres. Esta comparación permitió analizar cómo cambian las agrupaciones dependiendo de la cantidad de segmentos definidos y cuál modelo ofrece una interpretación más clara de los perfiles ocupacionales.

En el modelo de 4 clústeres se identificaron grupos con características diferenciadas. Uno de los grupos presentó altos niveles de educación, ingresos elevados y prestigio alto, representando ocupaciones altamente valoradas y especializadas. Otro grupo mostró niveles educativos e ingresos más bajos junto con menor prestigio, reflejando ocupaciones menos especializadas. También se identificó un grupo con alta participación femenina y prestigio medio-bajo, así como un grupo compuesto por ocupaciones con ingresos extremadamente altos y prestigio elevado.

Por otra parte, el modelo de 5 clústeres permitió separar de manera más específica las ocupaciones con menor prestigio e ingresos más reducidos. Esta segmentación adicional facilitó identificar perfiles ocupacionales más diferenciados y comprender mejor las características particulares de ciertos grupos.

La aplicación de K-Means permitió transformar datos numéricos en perfiles interpretables, facilitando la identificación de patrones ocupacionales dentro del dataset. Desde el contexto de producción industrial de software, este tipo de análisis puede utilizarse para segmentar perfiles laborales, identificar niveles de especialización técnica, clasificar equipos de trabajo y apoyar decisiones relacionadas con capacitación, asignación de roles y desarrollo organizacional.

Comparación entre modelo de 4 y 5 clústeres

Se desarrollaron dos modelos de clusterización utilizando el algoritmo K-Means: uno conformado por 4 clústeres y otro por 5 clústeres. Ambos modelos fueron construidos utilizando las mismas variables numéricas y el mismo proceso de escalamiento, permitiendo comparar directamente la forma en que las ocupaciones fueron agrupadas.

El modelo de 4 clústeres presenta una segmentación más general y equilibrada de las ocupaciones. En este modelo se identificaron grupos claramente diferenciados según variables como educación, ingresos y prestigio. Uno de los clústeres agrupó ocupaciones con altos niveles educativos y prestigio elevado, mientras que otro concentró ocupaciones con menor nivel educativo y prestigio medio-bajo. También se identificó un grupo caracterizado por una alta participación femenina y otro compuesto por ocupaciones con ingresos significativamente altos y prestigio superior al promedio.

Por otra parte, el modelo de 5 clústeres permitió una segmentación más específica, especialmente en los grupos de menor prestigio. Este modelo separó ocupaciones que anteriormente compartían características similares dentro de un mismo grupo, permitiendo distinguir perfiles ocupacionales más particulares. Como resultado, se obtuvo una clasificación más detallada de las ocupaciones con menores ingresos y niveles educativos reducidos.

A nivel interpretativo, el modelo de 5 clústeres ofrece una mayor capacidad de diferenciación entre perfiles, ya que permite identificar subgrupos con características más específicas. Sin embargo, el modelo de 4 clústeres presenta una interpretación más simple y comprensible, facilitando la lectura general de los resultados y la identificación rápida de patrones principales dentro del dataset.

Considerando el contexto del caso práctico y la necesidad de generar interpretaciones claras orientadas a la producción industrial de software, el modelo de 4 clústeres puede considerarse más útil para representar perfiles generales de ocupaciones, mientras que el modelo de 5 clústeres resulta más adecuado cuando se requiere un análisis más detallado o segmentado de los grupos.

En entornos organizacionales y tecnológicos, este tipo de comparación puede utilizarse para definir categorías de perfiles profesionales, niveles de especialización o segmentación de equipos de trabajo. De esta manera, la clusterización sirve para transformar datos numéricos en grupos interpretables que apoyan la toma de decisiones dentro de procesos de gestión y el análisis organizacional.

Captura de evidencia:

1. Implementación del algoritmo K-Means utilizando Python y escalamiento de variables mediante StandardScaler.

Actividad 4. Análisis de agrupación de ocupaciones

En esta actividad se aplicará clusterización para identificar grupos de ocupaciones con características similares. El estudiante debe construir a considera más útil para interpretar el caso.

```
In [22]: from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans

columnas_cluster = ['education', 'income', 'women', 'prestige', 'type_num']
X = df[columnas_cluster].copy()

escalador = StandardScaler()
X_escalado = escalador.fit_transform(X)

modelo_k4 = KMeans(n_clusters=4, random_state=42, n_init=10)
df['Cluster_4'] = modelo_k4.fit_predict(X_escalado)

modelo_k5 = KMeans(n_clusters=5, random_state=42, n_init=10)
df['Cluster_5'] = modelo_k5.fit_predict(X_escalado)

print(df.groupby('Cluster_4')[columnas_cluster].mean().round(2))
print(df.groupby('Cluster_5')[columnas_cluster].mean().round(2))
```

	education	income	women	prestige	type_num
Cluster_4					
0	13.59	7329.35	36.35	63.33	0.95
1	8.82	5878.74	9.60	37.26	2.09
2	10.12	3545.04	74.16	37.76	2.57
3	14.69	15746.83	6.00	74.23	1.00
Cluster_5					
0	10.94	3909.12	73.76	41.50	2.88
1	9.31	6922.03	5.84	42.18	2.25
2	13.59	7329.35	36.35	63.33	0.95
3	7.78	3327.48	34.10	26.87	1.71
4	14.69	15746.83	6.00	74.23	1.00

2. Comparación entre modelo de 4 y 5 clústeres, Centroides promedio obtenidos en el modelo de 4 clústeres y centroides promedio obtenidos en el modelo de 5 clústeres.

	education	income	women	prestige	type_num
Cluster_4					
0	13.59	7329.35	36.35	63.33	0.95
1	8.82	5878.74	9.60	37.26	2.09
2	10.12	3545.04	74.16	37.76	2.57
3	14.69	15746.83	6.00	74.23	1.00
Cluster_5					
0	10.94	3909.12	73.76	41.50	2.88
1	9.31	6922.03	5.84	42.18	2.25
2	13.59	7329.35	36.35	63.33	0.95
3	7.78	3327.48	34.10	26.87	1.71
4	14.69	15746.83	6.00	74.23	1.00

Actividad 5. Interpretación orientada a producción industrial de software

Justificación del modelo seleccionado

Después de comparar los resultados obtenidos mediante los modelos de 4 y 5 clústeres, se consideró que el modelo de 4 clústeres ofrece la interpretación más adecuada para el presente caso práctico. Aunque el modelo de 5 clústeres permite una segmentación más específica de ciertas ocupaciones, especialmente aquellas con menor prestigio e ingresos reducidos, el modelo de 4 grupos presenta una distribución más equilibrada y fácil de interpretar.

En el modelo de 4 clústeres fue posible identificar con mayor claridad perfiles ocupacionales generales, diferenciando ocupaciones con altos niveles educativos y prestigio elevado, ocupaciones con menor nivel de especialización y grupos con características particulares relacionadas con participación femenina e ingresos. Esta agrupación permitió obtener patrones más comprensibles y útiles para el análisis organizacional.

Por otra parte, el modelo de 5 clústeres generó una segmentación más detallada, pero algunos grupos presentaron diferencias muy pequeñas entre sí, dificultando una interpretación general más clara. Debido a esto, el modelo de 4 clústeres resulta más apropiado para representar perfiles ocupacionales de forma resumida y comprensible dentro del contexto del caso práctico.

Desde la perspectiva de producción industrial de software, trabajar con una cantidad moderada de grupos facilita la clasificación de perfiles profesionales, la toma de decisiones organizacionales y la interpretación de resultados para áreas de gestión del talento humano o especialización técnica. Por esta razón, se seleccionó el modelo de 4 clústeres como la mejor interpretación para el análisis desarrollado.

Hallazgos principales

Los resultados obtenidos mediante correlación, visualización y clusterización permitieron detectar patrones importantes dentro del conjunto de datos. Uno de los principales hallazgos fue la fuerte relación positiva entre el nivel educativo y el prestigio ocupacional. La variable education presentó la correlación más alta respecto a prestige, indicando que las ocupaciones que requieren mayor formación académica tienden a poseer una valoración social más elevada. De igual manera, el ingreso promedio también mostró una relación positiva importante con el prestigio, lo que evidencia que las ocupaciones mejor remuneradas suelen asociarse con mayores niveles de reconocimiento.

Otro hallazgo importante fue la existencia de distintos perfiles ocupacionales identificados mediante el algoritmo K-Means. La clusterización permitió agrupar ocupaciones con características similares, diferenciando grupos con altos niveles educativos y prestigio elevado, así como grupos con menores ingresos y menor valoración ocupacional. Además, algunos clústeres reflejaron una alta participación femenina junto con niveles de prestigio medio o bajo, mostrando patrones sociales interesantes dentro del dataset.

La comparación entre los modelos de 4 y 5 clústeres permitió observar que ambos enfoques ofrecen interpretaciones útiles, aunque con distintos niveles de detalle. El modelo de 4 clústeres facilitó una interpretación más general y comprensible de los perfiles ocupacionales, mientras que el modelo de 5 clústeres permitió identificar grupos más específicos, especialmente entre ocupaciones con menor prestigio.

Asimismo, los gráficos de dispersión confirmaron visualmente las relaciones detectadas en la matriz de correlación. Tanto la relación entre education y prestige como la relación entre income y prestige mostraron tendencias positivas claras, reforzando la consistencia de los resultados obtenidos mediante el análisis estadístico.

Desde una perspectiva aplicada a la producción industrial de software, estos hallazgos demuestran cómo las técnicas de minería de datos pueden utilizarse para segmentar perfiles profesionales, analizar características laborales y apoyar procesos de toma de decisiones. Este tipo de análisis puede servir para identificar niveles de especialización, necesidades de capacitación y estructuras organizacionales dentro de empresas tecnológicas orientadas al desarrollo de software.

Conclusiones y recomendaciones

El desarrollo del caso práctico permitió aplicar técnicas de análisis de datos y minería de datos utilizando Python sobre un conjunto de datos ocupacionales. A través de procesos de preparación de datos, correlación, visualización y clusterización con K-Means, fue posible identificar patrones relevantes relacionados con el prestigio ocupacional y las características asociadas a diferentes profesiones.

Uno de los principales resultados obtenidos fue la fuerte relación positiva entre el nivel educativo y el prestigio ocupacional, seguido de la relación entre ingresos y prestigio. Estos hallazgos indican que las ocupaciones con mayor formación académica y mejores niveles salariales tienden a presentar una valoración social más alta. Además, las visualizaciones gráficas permitieron confirmar visualmente estas relaciones, reforzando la consistencia del análisis estadístico realizado.

La aplicación del algoritmo K-Means permitió segmentar las ocupaciones en grupos con características similares, facilitando la identificación de distintos perfiles ocupacionales. La comparación entre los modelos de 4 y 5 clústeres mostró que ambos enfoques resultan útiles dependiendo del nivel de detalle requerido. El modelo de 4 clústeres proporcionó una interpretación más general y comprensible, mientras que el modelo de 5 clústeres permitió una segmentación más específica de ciertos perfiles ocupacionales.

Desde el contexto de producción industrial de software, este tipo de análisis puede utilizarse para clasificar perfiles técnicos, identificar niveles de especialización y apoyar procesos de gestión del talento humano dentro de organizaciones tecnológicas. Asimismo, las técnicas aplicadas pueden servir para analizar equipos de trabajo, detectar necesidades de capacitación y optimizar procesos de asignación de roles dentro de proyectos de desarrollo de software.

Como recomendación, sería conveniente complementar el análisis con variables adicionales relacionadas con experiencia laboral, habilidades técnicas, certificaciones, productividad y desempeño profesional. Esto permitiría construir modelos más completos y obtener interpretaciones más precisas sobre los perfiles ocupacionales.

Finalmente, este caso práctico demuestra la importancia del análisis de datos dentro de entornos organizacionales y tecnológicos, evidenciando cómo las herramientas de minería de datos pueden transformar información numérica en conocimiento útil para apoyar la toma de decisiones estratégicas.

Url al repositorio GitHub que contiene el dataset, notebook, README, documento final:

https://github.com/kevinnumanzor17/Caso_Practico-Tecnicas_Produccion